

Analyse par type d'attaque — VAE clean-only vs Dense autoencoder v1

Rapport technique — préparé pour Gérard

Périmètre : `06_attack_type_analysis/` , `07_segmented_injection/` , `08_dense_v1_comparison/`

1. Contexte et objectifs

Le suivi de vendredi a identifié 4 tâches, toutes en **inference-only** (aucun réentraînement de modèle) sur les modèles déjà entraînés (VAE clean-only `contam_0pct` , 20 seeds ; Dense autoencoder v1 `full_features` , 5 seeds) :

1. **Dériver un label `attack_type`** (portscan / apache_bench / slowloris) par flow dans le test set, alors que le pipeline ne produisait jusqu'ici qu'un label binaire `is_attack` , et **casser la métrique binaire agrégée** en performance par type d'attaque individuel.
2. Étendre cette analyse aux **combinaisons par paires** de types d'attaque, pour vérifier si un type mal détecté (apache_bench) devient plus facile à détecter quand il partage l'ensemble d'évaluation avec un type bien détecté.
3. Construire une **expérience d'injection segmentée** : au lieu du test set mélangé habituel, réordonner les mêmes flows en blocs contigus par type d'attaque (benign → apache_bench → benign → slowloris → benign → portscan → benign), pour visualiser le score de reconstruction en fonction de la position dans le flux et vérifier si le comportement du modèle change à la frontière d'un bloc.
4. **Répéter les 3 analyses précédentes avec le Dense autoencoder v1** (au lieu du VAE) pour déterminer si la faiblesse observée sur apache_bench est spécifique à l'architecture VAE ou si elle est partagée.

Aucune des données originales (`test_with_attack_type.csv` , `segmented_sequence.csv` , modèles `.keras`) n'a été modifiée entre les étapes — chaque script réutilise les fonctions du script précédent (`evaluate_group()` , `assemble_labeled_features_df()` , `compute_error_matrix()` , `run_segmented_evaluation()`) via un objet `backend` paramétrable (VAE ou Dense), sans dupliquer la logique de chargement de modèle / seuil / calcul de métriques.

Dérivation du label `attack_type`. `test_with_attack_type.csv` est construit par jointure entre `03_phase3_splits/test_indices.csv` et les logs d'orchestration (`ground_truth/attack_log.csv` , un log cumulatif par fenêtre de capture, filtré à l'intervalle propre de chaque fenêtre) sur la clé (`window_id` , `ts`) . Pour les fenêtres rééchantillonnées (`window_resampled_15pct/20pct` , ~31% des flows d'attaque du test set), qui n'ont pas leur propre `attack_log.csv` mais conservent le `ts` d'origine du flow source, la correspondance est faite **globalement** sur `ts` (tolérance 1s) plutôt que par `window_id` — les fenêtres réelles ne se chevauchant jamais dans le temps, cette approche résout correctement 100% des 3110 flows d'attaque du test set (taux de correspondance vérifié).

2. Performance par type d'attaque (analyse individuelle)

Protocole. Pour chaque type d'attaque, l'ensemble d'évaluation est : tous les flows benign du test set + uniquement les flows de ce type (les 2 autres types sont exclus de cette exécution). Seuil = `threshold_95` (95^e percentile de l'erreur de reconstruction sur les flows benign de validation), calculé par seed. Moyenne $\pm$ écart-type sur 20 seeds (VAE).

attack_type	n_attack	ROC-AUC	PR-AUC	F1 (thr95)	Benign FPR (thr95)	Attack Recall (thr95)
apache_bench	1487	0.5815 $\pm$ 0.0768	0.2133 $\pm$ 0.0219	0.0507 $\pm$ 0.0081	0.0565 $\pm$ 0.0059	0.0328 $\pm$ 0.0055
portscan	694	0.9982 $\pm$ 0.0005	0.9886 $\pm$ 0.0023	0.7737 $\pm$ 0.0161	0.0578 $\pm$ 0.0056	0.9889 $\pm$ 0.0138
slowloris	929	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.8271 $\pm$ 0.0158	0.0570 $\pm$ 0.0062	1.0000 $\pm$ 0.0000

(source : `06_attack_type_analysis/results_single_attack_type.csv/.md`)

Constat principal

apache_bench n'est quasiment jamais détecté : recall = 3.3%, F1 = 0.051, ROC-AUC = 0.58 (à peine mieux que le hasard). À l'inverse, portscan et slowloris sont détectés quasi parfaitement (recall $\geq$ 0.99, ROC-AUC $\geq$ 0.998).

Pourquoi la métrique binaire agrégée masque ce problème

Le test set contient 1487 flows `apache_bench`, 694 `portscan` et 929 `slowloris` — soit `apache_bench` = 47.8% des flows d'attaque, mais la métrique binaire `is_attack` habituelle (recall/F1 agrégé, voir par ex. les métriques Phase 3 existantes) mélange les 3 types dans un seul chiffre. Comme `portscan` et `slowloris` sont détectés à ~99-100%, ils tirent la moyenne globale vers le haut : un recall binaire global proche de 65-70% (cohérent avec les résultats historiques du contamination sweep, voir `phase3_vae/05_contamination_sweep/README.md`) peut coexister avec un type d'attaque presque totalement manqué. Sans décomposition par `attack_type`, cette faiblesse structurelle n'apparaît dans aucun rapport agrégé — d'où l'intérêt de cette analyse.

Cause probable (feature-level). `apache_bench` (`ab.exe` , requête HTTP fixe de 80 octets, `conn_state`=SF , durée < 1s) produit un flow qui ressemble, dans l'espace des 18 colonnes de features actuelles, à du trafic HTTP benign ordinaire — contrairement à `portscan` (ports non-HTTP, `conn_state` distinctif) et `slowloris` (connexion maintenue ouverte 30s+, `conn_state`=RST0/S1), qui ont une signature bien plus éloignée du comportement benign appris par les deux autoencodeurs.

3. Performance par paires de types d'attaque

Protocole. Pour chaque paire, l'ensemble d'évaluation est : tous les flows benign + les flows des 2 types de la paire (le 3^e type est exclu). Mêmes modèle/seuil que la section 2.

Paire	n_attack	ROC-AUC	PR-AUC	F1 (thr95)	Recall poolé (thr95)
portscan + apache_bench	2181	0.7135 ± 0.0527	0.5598 ± 0.0232	0.4447 ± 0.0070	0.3369 ± 0.0061
portscan + slowloris	1623	0.9993 ± 0.0002	0.9975 ± 0.0007	0.8905 ± 0.0105	0.9953 ± 0.0057
apache_bench + slowloris	2416	0.7427 ± 0.0474	0.6283 ± 0.0219	0.5170 ± 0.0054	0.4044 ± 0.0029

(source : 06_attack_type_analysis/results_pairwise_attack_type.csv/.md)

Recall poolé vs. recall décomposé — une distinction essentielle

Le recall "poolé" ci-dessus mélange les 2 types de la paire : il **augmente mécaniquement** dès qu'un type bien détecté (portscan ou slowloris) est ajouté à apache_bench, même si le comportement du modèle sur les flows apache_bench eux-mêmes ne change pas. Le seuil et le modèle étant fixes, la décision de flagger un flow ne dépend jamais des autres flows présents dans le set d'évaluation — c'est une propriété structurelle des deux autoencodeurs testés (décision statique par flow, sans mémoire de séquence).

Pour vérifier cela empiriquement, le recall a été **décomposé par sous-type** à l'intérieur de chaque paire :

Ensemble d'évaluation	Recall poolé (paire)	Recall apache_bench seul (décomposé)
apache_bench (solo)	—	0.0328 ± 0.0055
portscan + apache_bench (paire)	0.3369 ± 0.0061	0.0324 ± 0.0050
apache_bench + slowloris (paire)	0.4044 ± 0.0029	0.0322 ± 0.0048

(source : 06_attack_type_analysis/results_combined.md)

Confirmation empirique : le recall d'apache_bench ne change pas (0.0322-0.0328, à l'intérieur du bruit de seed) qu'il soit évalué seul ou en présence d'un autre type. La hausse apparente du recall "poolé" à 33-40% est un artefact du mélange, pas une amélioration réelle de la détection d'apache_bench — ce point est explicité pour éviter toute conclusion erronée du type « le pairing améliore la détection d'apache_bench ».

4. Expérience d'injection segmentée (blocs contigus)

Protocole. Les mêmes flows de test_with_attack_type.csv (aucune donnée synthétique, aucun rééchantillonnage avec remplacement) sont réordonnés en un flux unique : le pool benign est divisé en 4 segments quasi égaux, avec un bloc d'attaque contigu inséré entre chaque paire de segments benign, dans l'ordre configurable apache_bench → slowloris → portscan (07_segmented_injection/build_segmented_injection.py , ordre paramétrable via --order).




Figure 1 — Erreur de reconstruction (échelle log, moyenne sur 20 seeds) en fonction de la position dans le flux segmenté. Les lignes verticales marquent les frontières de segment ; la ligne pointillée horizontale est le `threshold_95` moyen. Le bloc `apache_bench` reste visuellement au niveau benign, alors que `slowloris` et `portscan` sautent immédiatement au-dessus du seuil.

Segment	n	Benign FPR (thr95)	Attack Recall (thr95)	F1 (thr95)	Recall test set mélangé (réf.)
benign (seg. 0)	1705	0.0305 ± 0.0070	—	—	—
apache_bench	1487	—	0.0322 ± 0.0044	0.0623 ± 0.0083	0.0328 ± 0.0055
benign (seg. 2)	1705	0.0336 ± 0.0078	—	—	—
slowloris	929	—	1.0000 ± 0.0000	1.0000 ± 0.0000	1.0000 ± 0.0000
benign (seg. 4)	1705	0.0962 ± 0.0222	—	—	—
portscan	694	—	0.9882 ± 0.0148	0.9940 ± 0.0075	0.9889 ± 0.0138
benign (seg. 6)	1706	0.0696 ± 0.0088	—	—	—

(source : `07_segmented_injection/results_segmented.md` , `threshold_95` moyen = 0.1246)

Confirmation : comportement statique, indépendant de l'ordre

Les recalls par bloc (0.0322 / 1.0000 / 0.9882) sont **quasi identiques** aux recalls du test set mélangé (0.0328 / 1.0000 / 0.9889) — la différence est du même ordre que le bruit de seed. Ceci confirme empiriquement que le VAE (comme le Dense autoencoder, voir section 5) est un détecteur **statique par flow, sans état ni mémoire de séquence** : qu'une attaque arrive isolée, mélangée à d'autres types, ou en bloc contigu ne change rien à la décision prise sur un flow donné.

Note de prudence — fluctuation du Benign FPR entre segments

Le FPR benign varie de **3.05% à 9.62%** selon le segment (vs. 5.75% en moyenne sur tout le pool benign en un seul bloc). Il serait tentant d'y lire un effet de "dérive" du modèle au fil du flux, mais **ce n'est probablement qu'un artefact d'échantillonnage** : chaque segment ne contient que ~1700 flows, une taille d'échantillon modeste pour un FPR attendu autour de 5-6% (l'intervalle de confiance à cette taille couvre largement l'écart observé). Le modèle n'a aucun état porté d'un flow à l'autre, donc aucun mécanisme plausible de dérive n'existe ici — cette fluctuation ne doit pas être interprétée sans un rejeu à plus grand n (segments plus larges, plus de seeds) pour la confirmer ou l'infirmer.

5. Comparaison VAE vs Dense autoencoder v1

Protocole. Les 3 analyses précédentes ont été répétées à l'identique (mêmes flows, mêmes 18 colonnes de features, même convention `threshold_95`) sur `phase3_dense/04_phase3_models/full_features` (5 seeds). Le Dense v1 n'ayant pas de fichier `threshold.json` sauvegardé par seed, le seuil est recalculé à la volée comme le 95^e percentile de l'erreur de reconstruction sur les flows benign de validation de `phase3_dense/03_phase3_splits` — convention reprise telle quelle de `analysis/attack_type_breakdown_evaluation.py`. Le Dense v1 consomme les mêmes colonnes `_scaled` que le VAE, sans scaler distinct (confirmé : les `row_index` de ses propres splits pointent tous dans `features_all_windows.csv`, sans offset vers les fenêtres rééchantillonnées).

Performance individuelle par type

attack_type	Modèle	ROC-AUC	PR-AUC	F1 (thr95)	Attack Recall (thr95)
apache_bench	VAE	0.5815 ± 0.0768	0.2133 ± 0.0219	0.0507 ± 0.0081	0.0328 ± 0.0055
apache_bench	Dense v1	0.6957 ± 0.0791	0.2704 ± 0.0406	0.0401 ± 0.0003	0.0262 ± 0.0000
portscan	VAE	0.9982 ± 0.0005	0.9886 ± 0.0023	0.7737 ± 0.0161	0.9889 ± 0.0138
portscan	Dense v1	0.9988 ± 0.0007	0.9912 ± 0.0032	0.7645 ± 0.0135	0.9931 ± 0.0155
slowloris	VAE	1.0000 ± 0.0000	1.0000 ± 0.0000	0.8271 ± 0.0158	1.0000 ± 0.0000
slowloris	Dense v1	1.0000 ± 0.0000	1.0000 ± 0.0000	0.8157 ± 0.0055	1.0000 ± 0.0000

(source : `08_dense_v1_comparison/results_single_attack_type_dense.csv/.md`)

Injection segmentée — Dense v1




Figure 2 — Même flux segmenté que la Figure 1, évalué avec le Dense autoencoder v1. Le bloc `apache_bench` forme une ligne quasi plate et déterministe (écart-type de recall = 0.0000 sur les 5 seeds), contrairement au nuage plus bruité du VAE (dû à l'échantillonnage stochastique de la reparamétrisation) — mais le niveau d'erreur reste comparable, bien en dessous du seuil.

Conclusion : la faiblesse sur `apache_bench` n'est pas spécifique à l'architecture

Le Dense autoencoder v1 rate `apache_bench` au moins aussi mal que le VAE (recall 2.6% vs 3.3%, F1 0.040 vs 0.051) — sur les 3 protocoles testés (individuel, paires, segmenté), les deux modèles échouent de

façon quasi identique. Une nuance intéressante : le Dense v1 a un **meilleur pouvoir de séparation brut** sur `apache_bench` (ROC-AUC 0.696 vs 0.581, PR-AUC 0.270 vs 0.213) — son score continu ordonne mieux les flows `apache_bench` par rapport au `benign` — mais cet avantage ne se traduit **pas** en meilleure détection au seuil `threshold_95` réel, chaque modèle étant calibré indépendamment sur sa propre distribution d'erreur `benign`.

Comparaison macro-moyenne (équilibre global entre types)

Modèle	Recall macro (3 types)	F1 macro (3 types)
VAE	0.6739	0.5505
Dense v1	0.6731	0.5401

L'écart entre les deux modèles (≤ 0.01) est **plus petit que la variance inter-seed du VAE lui-même sur `apache_bench` (std ROC-AUC = 0.077)** — aucun des deux modèles n'est donc de façon significative plus « équilibré » que l'autre entre les types d'attaque. Le motif est identique dans les deux cas : `portscan` et `slowloris` quasi parfaits, `apache_bench` presque totalement manqué.

(source complète : `08_dense_v1_comparison/comparison_vae_vs_dense.md`)

6. Conclusion générale

1. **La métrique binaire `is_attack` masque une faiblesse structurelle sévère sur `apache_bench`** (recall 2.6-3.3% selon le modèle), invisible dans les rapports agrégés existants car diluée par les 2 autres types d'attaque, détectés quasi parfaitement ($\geq 98.8\%$ de recall).
2. **Ce recall n'est pas amélioré par la co-présence d'un autre type d'attaque** dans l'ensemble d'évaluation (recall décomposé stable à ~ 3.2 -3.3% qu'`apache_bench` soit seul ou en paire) — la hausse du recall "poolé" observée en paire est un artefact de mélange de populations, pas une amélioration réelle de la détection.
3. **L'ordre d'arrivée des flows (mêlé vs bloc contigu) ne change rien** au comportement du modèle — confirmé empiriquement sur le VAE et le Dense v1, cohérent avec le fait que les deux sont des détecteurs statiques par flow, sans mémoire de séquence.
4. **La faiblesse sur `apache_bench` est partagée par le VAE et le Dense autoencodeur v1** — deux architectures différentes échouent de façon quasi identique, ce qui pointe vers une **limite du jeu de 18 features actuel** plutôt qu'un défaut d'un modèle en particulier. Changer d'architecture d'autoencodeur ne résoudra probablement pas ce problème seul.

Pistes pour la suite

- **Feature engineering ciblé sur la signature `apache_bench`** (requête HTTP fixe de 80 octets, `conn_state=SF`, durée $< 1s$) : des features actuellement absentes du pipeline (timing inter-requêtes, taux de requêtes par IP source sur une fenêtre glissante, ordre des octets dans la charge utile) pourraient mieux séparer ce trafic du HTTP `benign` — les 18 colonnes actuelles (durée/bytes/pkts agrégés + protocole/service/ `conn_state` one-hot) ne capturent pas la répétitivité qui distingue un benchmark HTTP automatisé d'une requête utilisateur isolée.

- **Seuil ou modèle spécifique par type d'attaque** (approche ensembliste) plutôt qu'un seuil unique global — étant donné que portscan et slowloris sont déjà quasi résolus, un second détecteur/seuil dédié à la signature HTTP courte pourrait cibler spécifiquement apache_bench sans dégrader les 2 autres types.
- **Élargir le rééchantillonnage benign par segment** avant de tirer des conclusions sur la fluctuation du FPR observée en section 4 (3-9.6%) — vérifier si elle persiste à un n plus grand par segment.